FleetMind-LLM｜Phase 5 实验与最终评测报告

实验范围：物流信息提取（Task A）与交付延误判断（Task B）
模型：Qwen/Qwen3-0.6B + SFT + 标准 LoRA
结论：以固定 Validation 选择 E1 后，E1 在封存的合成 Test 2,000 条指令上，Task A 字段准确率为 **8000/8000**，Task B Accuracy 为 **1000/1000**。这些是当前合成数据和题目范围内的实测结果，不代表真实业务场景的准确率。

1. 任务与实验设计

项目	定义
Task A	从物流记录文字中提取 `load_id`、`truck_id`、出发城市、目的城市、收入、耗油量、计划交付时间、实际交付时间，共 8 个字段；未提供的信息输出 JSON `null`。
Task B	比较实际与计划交付时间；实际时间更晚输出 `delayed`，否则输出 `on_time`。
E1 / E2 / E3	分别使用 1,600 / 4,000 / 8,000 条训练指令；三个 adapter 的 LoRA Rank 均为 **16**。
评测划分	同一份 Val 1,000 条（A/B 各 500）用于模型选择；最终 Test 2,000 条（A/B 各 1,000）仅在选定 E1 后使用。业务记录按划分隔离。
生成设置	`do_sample=False`、`enable_thinking=False`，Task A/B 的 `max_new_tokens` 分别为 192/48；三个模型在 Val 上按相同设置生成。

模型选择记录在 Test 生成之前写入，记录了 E1 adapter 权重哈希和 Val 指标。E1 的 LoRA 参数为 Rank 16、Alpha 32、Dropout 0.05，目标模块为 `q_proj`、`k_proj`、`v_proj`、`o_proj`。

2. 同一份 Validation 上的数据规模实验

三个模型各回答 500 道 Task A 和 500 道 Task B，逐题预测均已保存。

指标	E1：1,600	E2：4,000	E3：8,000
A JSON 有效	500/500	500/500	500/500
A 结构正确	500/500	500/500	500/500
A 字段准确率	4000/4000	4000/4000	4000/4000
A 空值准确率	197/197	197/197	197/197
A 整条记录完全正确	500/500	500/500	500/500
B Accuracy	**497/500（99.4%）**	**497/500（99.4%）**	**437/500（87.4%）**
B delayed F1	0.9955	0.9955	0.8966
B on_time F1	0.9908	0.9908	0.8389
B Macro-F1	0.9932	0.9932	0.8677
B on_time Recall	0.9818	0.9818	0.9939
B 无效输出	0	0	0

E2 的总体任务指标与 E1 持平，但错题并不完全相同。E3 保持 Task A 满分，Task B 却下降 60 题。E3 的 `on_time` Recall 略升，不能单独解释为整体改善：它将 **62 条真实延误误判为准时**。

E2 每轮 Val Loss 为 **0.6292 → 0.6473 → 0.6560**；E3 为 **0.6423 → 0.6729 → 0.6885**。两者均选择第 1 轮 checkpoint。后续 Val Loss 上升是需要警惕的信号，但不能单凭 Loss 确定错误成因。E1 训练期使用旧 Val 200，其训练期 Val Loss 不与 E2/E3 的 Val 1,000 Loss 直接比较；上述实际生成指标则来自同一份 Val 1,000。

3. 具体错误案例

固定 Val 中，E1 的 Task B 错误为 3/500，全部属于 **on_time → delayed** 的误报：

样本编号	计划交付	实际交付	标准 / E1 预测
`LOAD00019804_B`	2022-09-12 00:25:09.207790	2022-09-12 00:25:08.626945	on_time / delayed
`LOAD00009751_B`	2022-05-06 20:48:46.653640	2022-05-06 19:46:46.156002	on_time / delayed
`LOAD00019219_B`	2022-09-03 20:53:05.567555	2022-09-03 18:41:27.913466	on_time / delayed

这些错误不全是微秒边界：后两条实际交付比计划时间早了约 1 小时和 2 小时。E2 与 E1 共有两条错误，另将 `LOAD00035504_B` 误报为 delayed；因此两者“同为 497/500”并不表示每题答案一致。

E3 的 63 条 Task B 错误中，**61 条集中在 `validation_B_2`**（共 249 题）。这个模板先给出实际交付时间，再给出计划时间；61 条是 delayed 被判为 on_time。例子：

样本编号	实际交付	计划交付	标准 / E3 预测
`LOAD00016195_B`	2022-07-28 18:38:28.841312	2022-07-28 17:36:31.426882	delayed / on_time
`LOAD00003202_B`	2022-02-11 01:30:21.494072	2022-02-10 22:19:47.833966	delayed / on_time
`LOAD00031747_B`	2023-02-12 03:22:19.339113	2023-02-11 23:31:57.482075	delayed / on_time

这些时间相差约 1–4 小时。可以确认 E3 在这类表述上表现明显变差；现有实验不能证明“训练样本增加”是唯一原因，也不能把这些错误归因于微秒边界。

4. 模型选择与封存 Test

E1 与 E2 的 Val 任务指标相同；E1 使用更少训练指令，且 E3 的 Task B 显著退步，因此在查看 Test 成绩之前固定 **E1** 为最终模型。没有用 Test 结果重新选择模型或修改生成参数。

E1 最终 Test 指标	实测
样本数	2,000（Task A/B 各 1,000）
A JSON 有效 / 结构正确	1000/1000；1000/1000
A 字段准确率	**8000/8000（100%）**
A 空值准确率	**384/384（100%）**
A 整条记录完全正确	**1000/1000（100%）**
B Accuracy	**1000/1000（100%）**
B delayed F1 / on_time F1 / Macro-F1	**1.0000 / 1.0000 / 1.0000**
B on_time Recall / 无效输出	**1.0000 / 0**

Test 的 Task B 含 delayed **671** 条、on_time **329** 条；两类均全部判断正确。逐题预测共 2,000 条，编号无重复，标准答案与封存 Test 一致。Test 数据包的 SHA256 为 `700f21dc709f0eb40f1fcb323f0fa6ee675e7399c3e9b2fbd77f9f1cf1976473`。

5. 泛化分析与报告边界

1. **这是一份合成、同来源的留出测试。**训练、Val 和 Test 按业务记录隔离，但任务和文本模板仍属于同一套数据生成方式。Test 满分支持“当前合成分布内表现良好”，不支持“真实物流业务全面达到 100%”的说法。
2. **Val 与 Test 表现存在差异。**E1 在 Val Task B 为 497/500，而 Test 为 1000/1000。应同时报告两者，不用 Test 满分掩盖 Val 的三条误报。

3. **人工困难样本单独报告。**Phase 4 的 100 条人工困难样本中，E1 的 Task A 为 400/400 字段正确、Task B 为 45/50；五条 Task B 错误为同一类“晚 1 微秒”构造案例。这是有针对性的压力测试，不是独立同分布 Test，也不能与本次 2,000 条 Test 混算。
4. **任务范围有限。**Task B 当前仅覆盖交付延误二分类；没有评估费用风险、经营推理或实际线上文本。没有跨数据源、跨时间环境和多随机种子的稳定性实验。

6. 可复核文件

- `FleetMind_LLM_Phase3_Results.zip`：最终 E1 adapter、配置与 Phase 3 训练记录。
- `FleetMind_LLM_Phase5_E2_Results.zip`、`FleetMind_LLM_Phase5_E3_Results.zip`：规模实验的 adapter 与训练记录。
- `FleetMind_LLM_Phase5_Training_Data.zip`：E2/E3 训练数据与固定 Val。
- `FleetMind_LLM_Phase4_Evaluation_Dataset.zip`：封存 Test 与数据划分信息。
- `FleetMind_LLM_Phase5_Evaluation_Results.zip`：选型记录、Val/Test 指标、四份逐题预测、Loss 图与文件哈希清单。

最终 E1 adapter 权重 SHA256：`d79625e5b2073e7f7404633e00f784f375f4ea3a1625cfe01c1cbc1a501435aa`。本报告的数字来自已保存的评分文件及逐题预测；Phase 4 人工困难样本数字按该阶段的实验记录单独陈述。